

基于 Gabor 卷积神经网络的图像分类算法研究

王森妹, 刘海华*, 张安铎, 刘攸实

(中南民族大学 生物医学工程学院, 湖北 武汉 430074)

摘要: 为了研究 Gabor 滤波器在卷积神经网络中的性能和特征提取能力, 提出了模拟视觉神经元特性的 Gabor 卷积神经网络计算模型。利用符合视觉神经元感知特性的 Gabor 滤波器作为卷积神经网络的卷积核, 将 Gabor 滤波器与 CNN 相结合, 从而构建 Gabor 卷积神经网络。实验采用 3 个公共图像数据集进行图像分类任务, 验证 GaborConv 网络的各项性能, 并与经典的 VGG16 进行对比分析。实验结果表明, Gabor 卷积神经网络的图像分类精度相对 CNN 有所提高, 其收敛速度也明显加快, 同时大量减少网络训练参数数量, 释放计算机的内存。

关键词: Gabor 滤波器; 卷积神经网络; Gabor 卷积神经网络; 图像分类

中图分类号: TP18; TP391 **文献标识码:** A **文章编号:** 1001-7445(2021) 03-0675-08

Research on image classification algorithm based on Gabor convolutional neural network

WANG Sen-mei, LIU Hai-hua*, ZHANG An-duo, LIU You-shi

(College of Biomedical Engineering, South-Central University for Nationalities, Wuhan 430074, China)

Abstract: In order to study the performance and feature extraction abilities of Gabor filter in convolutional neural network, a computational model of Gabor convolutional neural network is proposed to simulate the characteristics of visual neurons. Used as the convolution kernel of the proposed neural network, the Gabor filter that conforms to the perception characteristics of visual neurons is combined with VGG16 to construct Gabor convolutional neural networks (GaborConv). The experiments use three public image data for image classification tasks, verify the performance of the Gabor Conv network, and compare them with the classic VGG16. The experimental results show that the image classification accuracy of Gabor convolutional neural network is improved in comparison with CNN, and its convergence speed is also significantly faster. At the same time, the number of network training parameters is greatly reduced and computer memory is released.

Key words: Gabor function; convolutional neural network; Gabor convolutional neural network; image classification

收稿日期: 2020-07-18; 修订日期: 2021-04-20

基金项目: 国家自然科学基金资助项目(61773409)

通讯作者: 刘海华(1966—), 男, 湖北武汉人, 中南民族大学教授; E-mail: lhh@mail.scuec.edu.cn。

引文格式: 王森妹, 刘海华, 张安铎, 等. 基于 Gabor 卷积神经网络的图像分类算法研究[J]. 广西大学学报(自然科学版), 2021, 46(3): 675-682.

0 引言

基于卷积滤波器的卷积神经网络,由于具有从原始图像像素学习特征的强大能力,在计算机视觉领域被广泛关注和应用。与传统的计算机视觉方法不同,卷积神经网络是多层次的人工神经网络,每个网络层都具有强韧的特征表达能力,对于输入图像的翻转、平移等形式变化具有高度识别性。卷积神经网络中的卷积层、激活层和池化层三个网络结构,能够避免传统神经网络的数据重建,并降低特征提取的困难。

卷积神经网络是一种数据驱动算法,它从数据中学习稳健的特征,但是通常以昂贵的训练和复杂的模型参数为代价^[1];此外,神经网络的收敛性取决于参数初始化。权值的初始化通常采用均匀分布或正态分布,但这会影响收敛问题,使得网络框架较深的网络在训练时收敛困难。在卷积神经网络中,第一层卷积层主要发挥着浅层特征提取器的作用。然而,一些深度可视化研究^[2-3],在 AlexNet^[4]、GoogLeNet^[5]等经典卷积神经网络模型中,观察第一层网络的卷积核形状,发现许多自适应滤波器最终收敛于 Gabor 滤波器,即使所有的滤波器都是随机初始化的;此外,第一层中提取特征的滤波器大多是重复的和有缺陷的。

生物研究^[6]表明,Gabor 小波具有生物学性质,与哺乳动物大脑视觉皮层的感受细胞的视觉机制十分相似,具有频率特性和方向特性,对图像的边缘信息敏感,能够有效提取边缘特征,感知纹理信息^[7],此外,Gabor 滤波器对于光照条件不敏感,在特征提取过程中不会受光照亮度影响。Gabor 滤波器被广泛应用于传统的计算机视觉方法中,目前,在深度学习领域已有部分研究^[8-9]。本文基于 Gabor 滤波器的优越生理特性和数学计算特性,针对卷积神经网络强大的学习能力及其存在的可改进之处,将两者融合,发挥各自优势。

理论上将 Gabor 滤波器作为卷积核来提取有效特征的能力会高于普通卷积核。根据 Gabor 滤波器的函数表达式可知,在反向传播的参数更新过程中,其只需学习更新 $\lambda, \theta, \psi, \gamma$ 四个参数(σ 与 λ 关联),可以有效地降低网络的训练复杂度,从而在保持较高的特征表现能力的同时,形成更加紧凑的深度学习模型^[10]。此外,根据 Gabor 滤波器的特性,在使用 Gabor 函数时,需要给定五个参数 $\lambda, \theta, \psi, \sigma, \gamma$ 的初始化范围和学习范围,避免随机初始化,提高网络的收敛速度。

基于 Gabor 滤波器的生物特性、提取特征的能力,以及在反向传播时参数更新量的优势,笔者提出一种改进卷积神经网络的方法,自定义 Gabor 卷积核与卷积神经网络相结合,形成 Gabor 卷积神经网络(gabor convolutional neural networks, GaborConv),网络中的 Gabor 卷积层从频域的不同尺度和方向上提取多层次特征,为网络的学习增加有效特征,提高学习能力。Gabor 卷积神经网络适用于图像识别、图像分类、图像分割等计算机视觉任务。本文研究表明,Gabor 卷积层在特征提取方面表现良好,处理复杂数据的能力优于卷积神经网络,且在网络中能有效减少训练参数数量,释放计算机内存占用。

1 二维 Gabor 卷积神经网络模型

1.1 二维 Gabor 滤波器

Gabor 滤波器是一种小波,其在数学领域的应用始于 1946 年,由英国的物理学家 Gabor 首先提出一维 Gabor 函数^[11]。到 1980 年,DAUGMAN^[12]将一维的形式扩展到二维,形成二维 Gabor 函数。Gabor 滤波器具有良好的时域和频域变换特性,可利用 Gabor 函数构造由不同参数引起的不同尺度方向的滤波器。Gabor 滤波器的生理特性是经过科学家的严谨证明得到的,文献[13]的研究表明一维 Gabor 函数可以很好地描述简单细胞的感受野。DAUGMAN 对视觉皮层感受野的分布进行了二维光谱分析,并证实了这种关系。所有简单的单元都可以用一组二维 Gabor 小波建模,在频域以对数方式采样。

本文采用的是二维 Gabor 滤波器,输入数据是二维图像。二维带通 Gabor 滤波器是由特定频率和方向的复正弦波调制的椭圆高斯包络线,其中谐波分量使滤波器对空间频率敏感,而高斯分量限制了对

输入图像局部区域的频率敏感程度。Gabor 函数的复数表达形式如下:

$$g(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \exp\left[i\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right)\right], \quad (1)$$

实数部分表达形式为

$$g_{\text{re}}(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \cos\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right), \quad (2)$$

虚数部分表达形式为

$$g_{\text{im}}(x, y; \lambda, \theta, \psi, \sigma, \gamma) = \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \sin\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right), \quad (3)$$

其中:

$$\begin{cases} \bar{x} = x \cos(\theta) + y \sin(\theta) \\ \bar{y} = -x \sin(\theta) + y \cos(\theta) \end{cases} \quad (4)$$

Gabor 函数的各个参数对滤波器的形态均有不同的影响,其中, θ 表示滤波器的方向,本文选择的取值范围是 $0 \sim \pi$; λ 表示滤波器的波长,其值以像素为单位; ψ 表示 Gabor 函数的中正弦或余弦因子参数的相位偏移,本文的取值范围是 $0 \sim \pi$; γ 表示空间纵横比,人眼的最佳接收范围^[14] 是 $(0.3 \sim 0.7)$; σ 是 Gabor 函数的高斯因子标准差,其值由带宽 b 决定。

$$b = \log_2 \left(\frac{\frac{\sigma}{\lambda} \pi + \sqrt{\frac{\ln 2}{2}}}{\frac{\sigma}{\lambda} \pi - \sqrt{\frac{\ln 2}{2}}} \right). \quad (5)$$

标准差 σ 和 波长 λ 相互关联,两者的关系式如式(6)所示。

$$\frac{\sigma}{\lambda} = \frac{1}{\pi} \sqrt{\frac{\ln 2}{2}} \left(\frac{2^b + 1}{2^b - 1} \right), \quad (6)$$

在 Gabor 滤波器中,带宽 b 的值通常设置为 1,当 $b = 1$ 时, λ 和 σ 之间的关系为 $\frac{\sigma}{\lambda} \approx 0.56$ 。公式(7)为高斯函数表达式:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]. \quad (7)$$

Gabor 函数是复正弦波调制的椭圆高斯包络线,其中高斯函数图像的区间取值范围与滤波器核尺寸的大小相互关联。由式(7)可知,窗口尺寸大小的选择取决于参数 σ ,在高斯函数图像中,函数曲线在 $(\mu - 3\sigma, \mu + 3\sigma)$ 的区间范围内时,所占面积约为总面积的 99.7%,因此,当半径为 3σ ,即窗口大小为 $6\sigma \times 6\sigma$ 时,窗口尺寸几乎能包含 99% 以上的有效范围。图 1 所示为高斯函数曲线在 $(\mu - \sigma, \mu + \sigma)$, $(\mu - 2\sigma, \mu + 2\sigma)$, $(\mu - 3\sigma, \mu + 3\sigma)$ 三种取值区间的覆盖范围。

1.2 网络结构

在设计一个深度神经网络时,除了网络的学习性能之外,网络训练参数数量也是不可忽视的问题。在神经网络中,感受野需要覆盖整个相关图像区域,因为在图像预测时,需要一个足够大的感受野来捕获每个像素周围的局部上下文信息。现存的一些改进感受野的研究,尝试着扩展感受野,将大尺寸的卷积核在浅层




图1 高斯函数曲线图像

Fig. 1 Gaussian function curve image

卷积层使用,或使用小尺寸卷积核堆叠几层。然而,增大感受野的大小,会导致可训练参数的数量和计算成本的快速增长。

在一个标准的卷积层中,设有 K 个尺寸为 $m \times m$ 的卷积核,以及 c 个输入特征,那么该卷积层的可训练参数数量为 $(m \times m \times c + 1) \times K$,相比之下,对于本文所提出的 Gabor 卷积层而言,每个 Gabor 卷积核只需更新 4 个参数(σ 与 λ 关联),无论卷积核尺寸多大,相同条件下,Gabor 卷积层的可训练参数数量为 $(4 \times c + 1) \times K$ 。因此,将 Gabor 卷积核作为特征提取器,有利于设计更紧凑的网络。Gabor 卷积神经网络前向传播和反向传播过程如图 2 和图 3 所示。

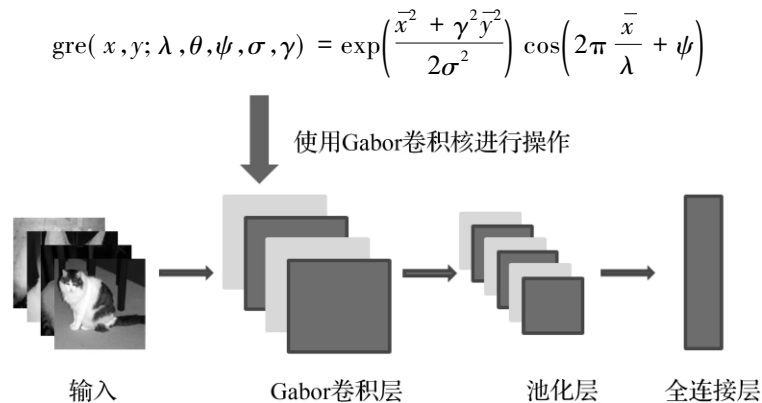


图2 Gabor 卷积神经网络前向传播

Fig. 2 Forward propagation of Gabor convolutional neural network

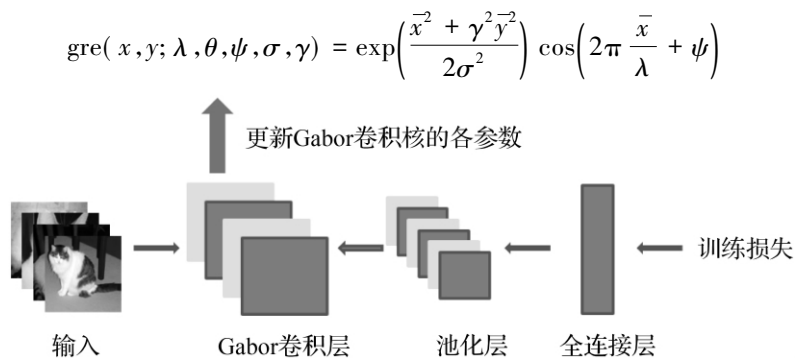


图3 Gabor 卷积神经网络反向传播

Fig. 3 Back propagation of Gabor convolutional neural network

VGGNet 是卷积神经网络的经典模型^[15],是由 Karen Simonyan 和 Andrew Zisserman 在 ILSVRC2014 竞赛中提出的一种网络模型,VGGNet 的创新之处在于将小尺寸的卷积核堆叠代替大尺寸卷积核,2 个 3×3 的卷积核可以代替 5×5 的卷积核,并且不影响网络效果,这样在很大程度上减轻了计算量。VGG16 是随后被广泛使用的一种模型,其由 13 层卷积层和 3 层全连接层组成,每个卷积层后面都紧接着 ReLU 激活函数和 BatchNorm 层,网络输入为 224×224 的三通道彩色图像。

本文关于 Gabor 卷积核的网络主要基于 VGG16 的网络模型,其结构如图 4 所示。图 4(a) 为 VGG16 网络的具体结构;图 4(b)、图 4(c) 为基于 VGG16 搭建的 GaborConv13 网络结构。GaborConv13 网络是将 VGG16 网络的第一层普通卷积核替换为 Gabor 卷积核,使第一个卷积层变为 Gabor 卷积层。图 4(b) 所示网络结构用于 CIFAR10 数据集,该数据集图像尺寸仅为 32×32 ,因此 Gabor 卷积核的尺寸设为 5×5 。图 4(c) 所示网络结构用于猫狗和 Mini-imagenet 数据集,图像尺寸为 224×224 ,Gabor 卷积核的尺寸设为 9×9 ,并将第一个 Maxpool 设为 4×4 ,加快特征图尺寸缩减。三个网络结构中,每个卷积层后面都会加 BatchNorm 层和 ReLU 激活函数。本文将 GaborConv13 和 VGG16 两个网络模型作为实验对比

模型,在上述3个自然图像分类数据集上开展实验,并根据网络训练过程中的训练损失图、网络分类精确度以及网络训练参数数量3个指标来评价网络的整体效果。

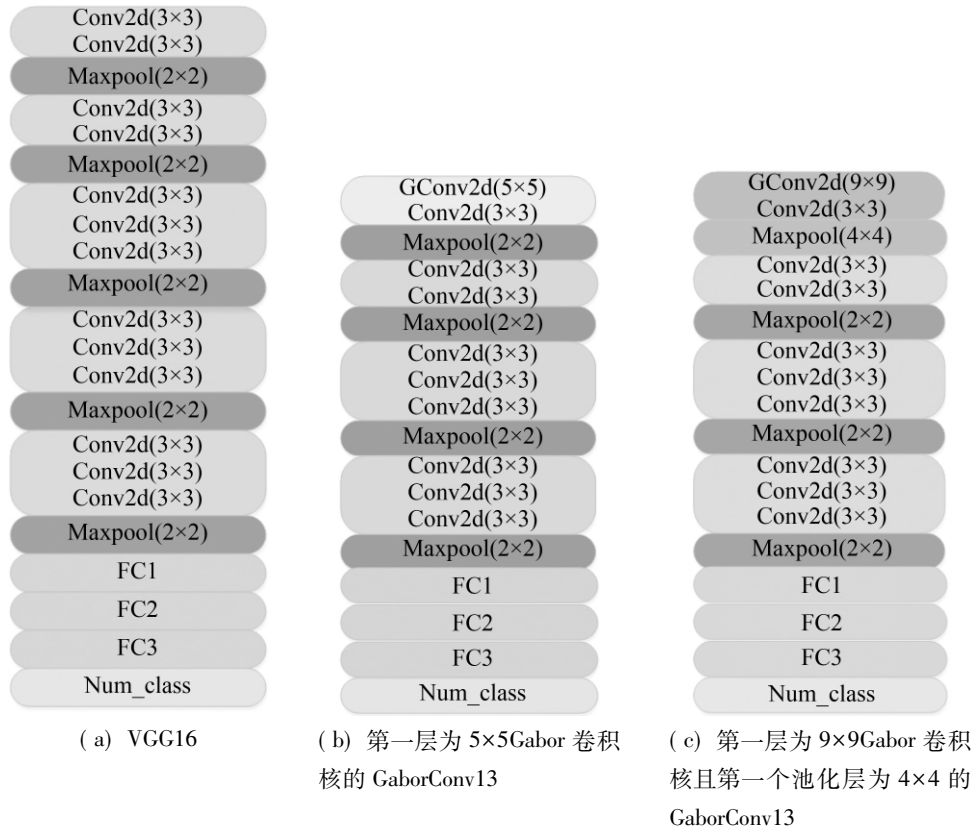


图4 本文实验所用网络结构

Fig. 4 Network structure used in the experiment in this paper

1.3 二维 Gabor 卷积的反向传播过程

在 Gabor 卷积核中,需要对每个 Gabor 滤波器的参数进行优化。梯度下降算法通过反向传播^[16]的方式,根据目标函数调整优化滤波器的参数,而 Gabor 卷积核同样通过反向传播的学习方法来获取反映视觉属性的 Gabor 滤波器参数,本节将对 Gabor 函数的反向传播做简要的推导。设 L 为损失, α 为学习率, p 为需要更新的参数,其中 $p \in \{\lambda, \theta, \psi, \sigma, \gamma\}$, 参数更新遵循误差反向传播算法:

$$p_{t+1} = p_t + \alpha \times \frac{\partial L_{\text{total}}}{\partial p}, \quad (8)$$

$$\frac{\partial L_{\text{total}}}{\partial p} = \frac{\partial L}{\partial g_{\text{re}}} \times \frac{\partial g_{\text{re}}}{\partial p}, \quad (9)$$

则 Gabor 函数中的 5 个参数更新的公式如下:

$$\frac{\partial g_{\text{re}}}{\partial \lambda} = \frac{2\pi \bar{x}}{\lambda^2} \times \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \sin\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right) = \frac{2\pi \bar{x}}{\lambda^2} \times g_{\text{im}}, \quad (10)$$

$$\frac{\partial g_{\text{re}}}{\partial \theta} = \frac{g_{\text{re}} \bar{x} \bar{y}}{\sigma^2} (\gamma^2 - 1) - \frac{2\pi \bar{y}}{\lambda} \times g_{\text{im}}, \quad (11)$$

$$\frac{\partial g_{\text{re}}}{\partial \psi} = -\exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \sin\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right) = -g_{\text{im}}, \quad (12)$$

$$\frac{\partial g_{\text{re}}}{\partial \sigma} = \frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{\sigma^3} \times \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \cos\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right) = \frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{\sigma^3} \times g_{\text{re}}, \quad (13)$$

$$\frac{\partial g_{re}}{\partial \gamma} = -\frac{\gamma \bar{y}^2}{\sigma^2} \times \exp\left(-\frac{\bar{x}^2 + \gamma^2 \bar{y}^2}{2\sigma^2}\right) \cos\left(2\pi \frac{\bar{x}}{\lambda} + \psi\right) = -\frac{\gamma \bar{y}^2}{\sigma^2} \times g_{re} \circ \quad (14)$$

根据以上的公式,Gabor 函数的各个参数在网络训练过程中不断迭代更新。梯度下降算法根据上述对参数求偏导的方式进行扩展,以此将所有错误损失归因于 Gabor 函数的参数,而不是归结于滤波器结构,因此,可以通过更新滤波器参数来调整滤波器,从而避免盲目调整滤波器结构而忽略网络结构。

2 实验结果与分析

本文实验环境为 Centos 系统,配置了 Intel(R) Xeon(R) Gold 5118 CPU @ 2.30 GH 和 NVIDIA Tesla V100-SXM2 显卡的大型浪潮服务器,软件环境为 anaconda4.5.4,Python3.6.9,Pytorch1.1.0。网络模型的初始学习率均为 0.001,每迭代 20 次减小 10 倍,优化器选择 SGD。

根据上述提出的对比实验方案,开展了相应的实验验证 Gabor 卷积神经网络的可行性,检验其在计算机视觉任务中的表现。本文开展实验对自然图像数据集进行分类,选用 Cat&Dog 数据集、CIFAR10 数据集和 Mini-imagenet 分类数据集。其中,Cat&Dog 数据集是 Kaggle 竞赛的比赛数据集;Mini-imagenet 数据集节选自 ImageNet 数据集,DeepMind 团队首次将其用于小样本学习研究,Cat&Dog 和 Mini-imagenet 的图像尺寸均处理为 224×224;CIFAR10 是由 Hinton 的学生 Alex Krizhevsky 和 Ilya Sutskever 整理的一个用于识别普适物体的小型数据集,其图像尺寸为 32×32。本文使用 VGG16 网络模型和 GaborConv13 网络模型对三个数据集进行分类任务。图 5 所示为两个网络模型在每个数据集上的训练损失对比图,从训练损失曲线可以看出,GaborConv13 的收敛速度比 VGG16 有所提升。

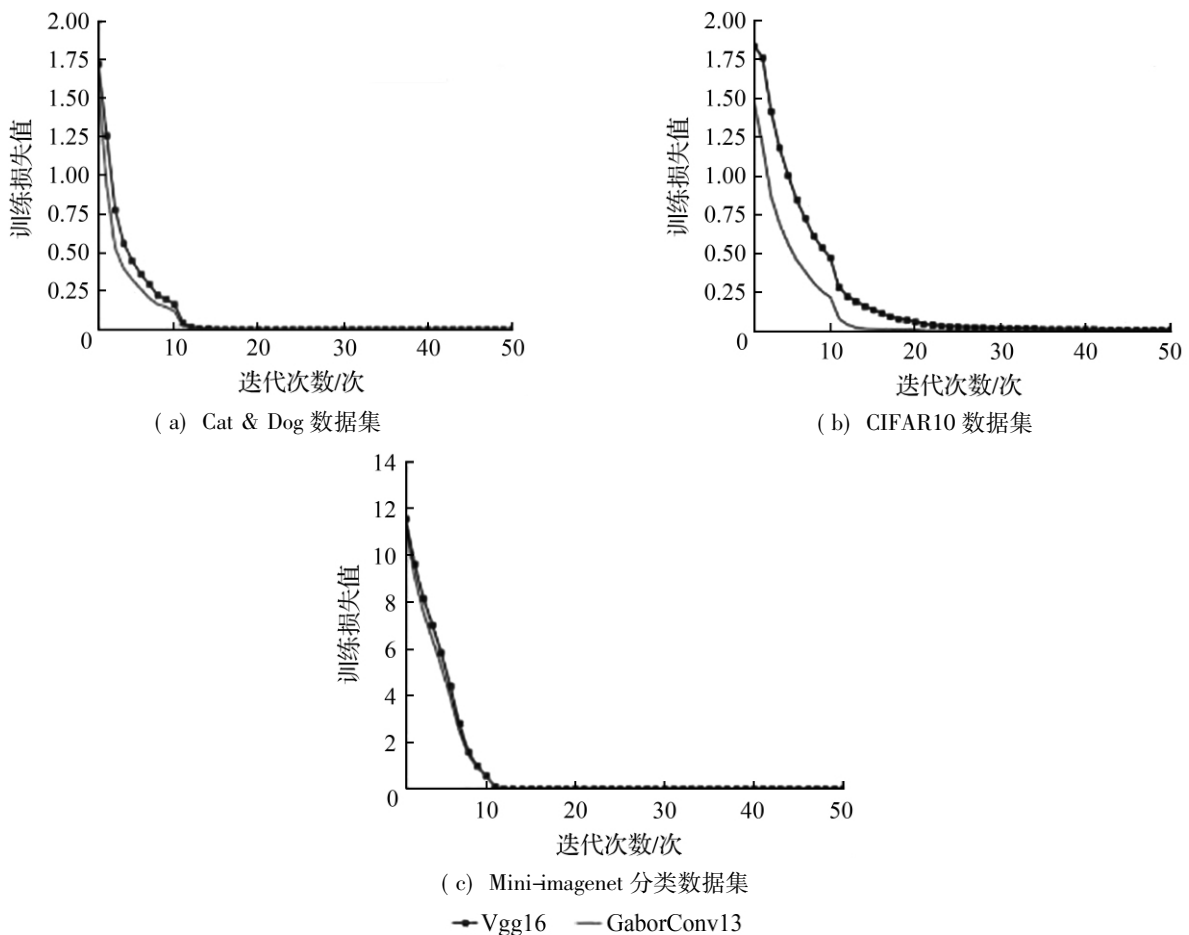


图 5 VGG16 和 GaborConv13 两个网络模型在三个数据集上的训练损失

Fig. 5 Training loss of two network models VGG16 and Gaborconv13 on three data sets

表1对比了VGG16和GaborConv13两个网络模型在三个图像分类数据集上的测试分类精确度。从表1中可知,GaborConv13在缩减网络层数的情况下,在三个数据集上的测试分类精确度均优于VGG16。由实验结果可知,Gabor卷积核的方向性核频率特性在特征提取中发挥优势,使得GaborConv13网络性能优于VGG16。GaborConv13网络的性能与Gabor卷积核的参数设置有很大关联,因此,对Gabor函数的各参数深入研究很有必要。

表1 两个网络模型在三个数据集上的分类精确度

Tab.1 Accuracy of two network models on three data sets

%

网络模型	Cat&Dog	CIFAR10	Mini-imagenet(Top5)
VGG16	95.90	83.35	69.31
GaborConv13	96.21	85.81	71.60

表2分别比较了两个网络模型的第一层参数量和网络总体参数量,由于GaborConv13的第一层使用Gabor卷积核,有效压缩了网络模型的深度,与VGG16相比,GaborConv13模型不仅第一层参数量减少,而且网络总参数量也大幅度降低,减轻了网络的计算量。

表2 两个网络模型的参数量对比

Tab.2 Comparison of the number of parameters of the two network models

网络模型	第一层参数量/个	总参数量/个	模型大小/MB
VGG16	1 792	1.34×10^8	128.35
GaborConv13	320	0.99×10^8	37.73

为了对比GaborConv13模型与其他研究方法的网络性能,采用CIFAR10数据库进行实验比较,具体的对比结果见表3。文献[17]主要通过在卷积层中加入正则化方法来减少计算开销,然而提出的方法并不能减少参数量;文献[18]提出了一种新型卷积模块,该方法在保证分类精确度的同时,能够在低容量硬件上部署较大的网络,减少计算量,不过与GaborConv13相比,其卷积层的参数量并没有降低;文献[19]采用的半监督学习,引入自集成方式,有效提高分类精度,与其相比,本文在CIFAR10上的分类精确度略低,但本文的研究目的与其不同,本文主要研究Gabor卷积核的特征提取能力及网络模型参数量。总体而言,本文的研究内容具有较好的研究意义,所提出研究方法具有一定优势。

表3 不同研究方法在CIFAR10上的分类精确度

Tab.3 Classification accuracy of different research methods on CIFAR10

研究方法	分类精确度/%
文献[17]	84.87
文献[18]	85.02
文献[19]	87.84
GaborConv13	85.81

3 结论

实验研究和实验结果表明,本文设计的Gabor卷积核,其特征提取能力优于普通卷积核,Gabor卷积核的使用能够降低神经网络的深度,并且能达到与卷积神经网络的一样学习效果,同时减少网络参数数量,一定程度上解决深层的卷积神经网络的学习对计算机内存的占用问题。总体而言,实验效果达到预期期望,在之后的学习中,会尝试将二维Gabor卷积神经网络运用在其他的计算机视觉的任务当中,检验网络的鲁棒性。今后的学习研究中,考虑将Gabor滤波器与卷积神经网络的研究往两个方向开展,其

一,在二维层面,考虑是否研究 Gaussian 卷积核,并将 Gabor 卷积核与之随机混合使用;其二,将二维 Gabor 滤波器扩展到三维层面,自定义三维 Gabor 卷积核,用于三维的计算机视觉任务。这是根据目前的研究成果所设想出的两种研究思路,在后期的科研任务中,会继续深入研究。

参考文献:

- [1] LUAN S, CHEN C, ZHANG B, et al. Gabor convolutional networks [J]. IEEE Transactions on Image Processing, 2018,27(9): 4357-4366.
- [2] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks [J]. Lecture Notes in Computer Science, 2014,8689(1): 818-833.
- [3] LIU D, CUI W, JIN K, et al. Deepticker: Visualizing the training process of convolutional neural networks [J]. ACM Transactions on Intelligent Systems and Technology, 2018,10(1): 1-25.
- [4] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks [J]. Advances in Neural Information Processing Systems, 2012,25(2): 1097-1105.
- [5] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions [C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, USA: IEEE, 2015: 1-9.
- [6] JONES J P, PALMER L A. An evaluation of the two-dimensional gabor filter model of simple receptive fields in cat striate cortex [J]. Journal of Neurophysiology, 1987,58(6): 1233-1258.
- [7] JONES J P, PALMER L A. An evaluation of the two-dimensional gabor filter model of simple receptive fields in cat striate cortex [J]. Journal of Neurophysiology, 1987,58(6): 1233-1258.
- [8] ZHANG Y, LI W, ZHANG L, et al. Adaptive learning gabor filter for finger-vein recognition [J]. IEEE Access, 2019,7: 159821-159830.
- [9] LE H T, PHUNG S L, CHAPPLE P B, et al. Deep gabor neural network for automatic detection of mine-like objects in sonar imagery [J]. IEEE Access, 2020,8: 94126-94139.
- [10] ALEKSEEV A, BOBE A. GaborNet: Gabor filters with learnable parameters in deep convolutional neural network [C]// 2019 International Conference on Engineering and Telecommunication (EnT). Dolgoprudny, Russia: IEEE, 2019: 1-4.
- [11] GABOR D. Theory of communication. Part I: The analysis of information [J]. Journal of the Institution of Electrical Engineers-Part III: Radio and Communication Engineering, 1946,93(26): 429-441.
- [12] DAUGMAN J G. Two-dimensional spectral analysis of cortical receptive field profiles [J]. Vision Research, 1980,20(10): 847-856.
- [13] MARÇELJA S. Mathematical description of the responses of simple cortical cells [J]. Journal of the Optical Society (JOSA), 1980,70(11): 1297-1300.
- [14] 王博馨. Gabor 小波参数对人脸特征的影响机理 [D]. 西安: 西安科技大学, 2019.
- [15] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition [J]. Computer Science, 2014,15: 1556-1570.
- [16] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors [J]. Nature, 1986,323(6088): 533-536.
- [17] ZEILER M D, FERGUS R. Stochastic pooling for regularization of deep convolutional neural networks [J]. Computer Science, 2012,7575(1): 702-715.
- [18] FREEMAN I, ROESE-KOERNER L, KUMMERT A. EffNet: An efficient structure for convolutional neural networks [C]//2018 25th IEEE International Conference on Image Processing (ICIP). Athens, Greece: IEEE, 2018: 6-10.
- [19] LAINE S, AILA T. Temporal ensembling for semi-supervised learning [C]//5th International Conference on Learning Representations, ICLR 2017. Toulon, France: ICLR, 2017: 1-13.

(责任编辑 梁碧芬)