

# 基于深度学习的轻量化田间昆虫识别及分类模型

袁哲明<sup>1,2</sup>, 袁鸿杰<sup>1,2</sup>, 言雨璇<sup>2</sup>, 李 钊<sup>2,3</sup>, 刘双清<sup>4</sup>, 谭泗桥<sup>1,2</sup>

(1. 湖南农业大学 湖南省农业大数据分析决策工程技术研究中心, 长沙 410128; 2. 湖南农业大学 湖南省农村农业信息化工程技术研究中心, 长沙 410128; 3. 湖南农业大学 商学院, 长沙 410128; 4. 湖南农业大学 植物保护学院, 长沙 410128)

**摘 要:** 由于田间昆虫环境的复杂性、昆虫类别间样本数量的不均衡性, 现有田间昆虫自动识别和分类方法存在误识率高、效率低等缺点。本文基于轻量化深度学习模型提出了新的田间昆虫自动识别和分类算法。首先, 对田间昆虫图像进行预处理, 将其输入到轻量化算法中进行特征提取, 通过多尺度特征融合输出不同尺寸的预测网络。然后, 引入联合交并比进行田间昆虫自动识别和分类。最后, 与其他算法进行了仿真对比实验, 结果表明, 本文算法的田间昆虫自动识别和分类正确率高、用时少、鲁棒性强, 有效解决了昆虫堆积、背景干扰等问题, 可实时、在线识别田间昆虫。

**关键词:** 模式识别; 深度学习; 目标检测; 昆虫分类; 轻量化算法; 图像预处理

**中图分类号:** TP181 **文献标志码:** A **文章编号:** 1671-5497(2021)03-1131-09

**DOI:** 10.13229/j.cnki.jdxbgxb20200116

## Automatic recognition and classification of field insects based on lightweight deep learning model

YUAN Zhe-ming<sup>1,2</sup>, YUAN Hong-jie<sup>1,2</sup>, YAN Yu-xuan<sup>2</sup>, LI Qian<sup>2,3</sup>, LIU Shuang-qing<sup>4</sup>, TAN Si-qiao<sup>1,2</sup>

(1. Hunan Engineering & Technology Research Center for Agricultural Big Data Analysis & Decision-making, Hunan Agricultural University, Changsha 410128, China; 2. Hunan Engineer Research Center for Information Technology in Agriculture, Hunan Agricultural University, Changsha 410128, China; 3. Business School, Hunan Agricultural University, Changsha 410128, China; 4. College of Plant Protection, Hunan Agricultural University, Changsha 410128, China)

**Abstract:** Due to the complexity of the insect environment in the field and the imbalance in the number of samples among insect categories, the existing automatic identification and classification methods for field insects have high misidentification rates and low efficiency. In this paper, a new field insect automatic identification and classification algorithm is developed based on a lightweight deep learning model. First,

**收稿日期:** 2020-02-25.

**基金项目:** 国家自然科学基金项目(31772157); 中央引导地方科技发展专项资金项目(2019XF5015); 湖南省教育厅科学研究项目(17C0757).

**作者简介:** 袁哲明(1971-), 男, 教授, 博士生导师. 研究方向: 生物信息学, 复杂数据分析.

E-mail: zhmyuan@sina.com

**通信作者:** 谭泗桥(1974-), 男, 教授, 博士. 研究方向: 模式识别与预测. E-mail: tsq@hunau.edu.cn

preprocessing applied to the picture, then those images were input to the lightweight algorithm for feature extraction, and multi-scale feature fusion were adopted to output prediction networks of different sizes; then introduce joint cross-comparison for automatic identification and classification of field insects, and finally compare with the reference. The algorithm has been simulated and compared. The results show that the field insect automatic identification and classification of the algorithm in this paper has high accuracy, less time, and strong robustness. It effectively solves the problems of insect accumulation and background interference and can identify field insects in real-time and online.

**Key words:** pattern recognition; deep learning; object detection; insect classification; lightweight algorithm; image preprocessing

## 0 引言

农田虫害预测是精准农业和现代化农业当中的重要内容,传统昆虫监控依赖工作人员的经验,工作量大、时效性差,无法满足当前害虫发生监测的需求,阻碍了农业病虫害防治过程中的快速决策<sup>[1-3]</sup>。近年来,计算机视觉技术的飞速发展,为实现昆虫自动识别和计数提供了技术基础,其中基于图像处理技术的昆虫自动识别技术成为了研究热点。基于图像处理技术的传统昆虫自动识别的基本步骤为:昆虫图像采集和预处理、昆虫图像特征的提取和优化、分类器设计<sup>[4]</sup>。最初,研究者采用人工神经网络、支持向量机等,根据昆虫的颜色、形态和纹理等特征设计昆虫自动识别的分类器,但是在实际应用中,人工神经网络基于经验风险最小化原则,要求的昆虫自动识别学习样本数量大,昆虫自动识别结果极不稳定,经常得到“过拟合”的结果,可信度较低;而支持向量机基于结构风险最小化原则,昆虫自动识别过程十分复杂,计算时间长、收敛速度慢,无法进行昆虫自动在线识别,缺陷十分明显<sup>[5]</sup>。深度学习具有收敛速度快、对昆虫自动识别学习样本数量要求低等优点,有学者尝试将其应用于昆虫自动识别研究工作当中,并取得了一定的研究成果,如:周爱明等<sup>[6]</sup>提出基于CaffeNet的蝴蝶自动识别算法,结果表明,基于CaffeNet的蝴蝶分类效果远好于支持向量机;Cheng等<sup>[7]</sup>使用深度残差网络对10种复杂背景下的昆虫进行分类,昆虫自动识别正确率为98.67%,而对于相同的数据集,支持向量机的昆虫自动识别正确率仅为44.00%,但是他们只是针对单个类型的昆虫自动识别和分类研究。张银松等<sup>[8]</sup>提出Faster R-CNN<sup>[9]</sup>的两类型昆虫自动识别算法数,其识别正确率达到90.7%,而昆虫自

动识别实用性仍有待改善<sup>[10]</sup>。

针对当前算法只针对单类型或者两种类型的昆虫自动识别,无法对自然环境条件的昆虫进行在线监测和识别的问题,本文提出了基于轻量化深度学习模型的田间昆虫自动识别和分类算法,该算法基于YOLOv3<sup>[11]</sup>目标检测框架,在特征提取层中集成了深度可分离卷积(Depthwise separable convolution, DSC)<sup>[12,13]</sup>,大幅减少了计算量,通过多尺度特征融合输出不同尺寸的预测网络,保证对不同尺寸昆虫的检测效率,并且引入联合交并比(Generalized intersection over union, GIoU)提升了网络预测目标的准确性。最后,与当前经典算法进行了对比实验,结果表明,本文算法获得了较高的田间昆虫自动识别和分类正确率,同时加快了田间昆虫自动识别和分类效率,具有广泛的应用前景。

## 1 本文算法

### 1.1 模型架构

YOLO系列目标检测算法一直以其极快的检测速度和相对可靠的正确率著称,YOLOv3在YOLO<sup>[14]</sup>和YOLOv2<sup>[15]</sup>的基础上发展而来,在卷积网络中,浅层网络关注于细节信息,深层网络关注于语义细节信息,深层的语义信息有助于准确检测出目标,但是浅层细节信息可以提升检测的正确率,仅利用少量的深层信息可能会降低检测的性能。为此,本文设计了基于轻量化深度学习模型的田间昆虫自动识别和分类算法,其架构如图1所示。

首先,图像输入到算法当中首先通过特征提取网络,并输出3张不同尺寸的特征图;然后,采用特征金字塔网络(Feature pyramid networks, FPN)<sup>[16]</sup>思想对特征提取网络中不同尺寸的特征层进行预测,使用上采样(Upsample)和特征融合

将多个尺度的特征信息融合在一起;最后,在多个尺度的融合特征图上分别独立做检测,该结构有助于提升网络的预测正确率,同时加强了网络对不同尺寸昆虫的识别能力。在特征预测图中,从特征提取层当中输入的特征图被划分为 $S \times S$ 个网格,网格负责预测中心点落入网格内部的目标。每个网格生成3个不同尺寸的预测框,用于对不同尺寸的目标进行预测,每个预测框有 $1 + 4 + C$

个参数,包括1个目标置信度 $p_r(\text{Object})$ ,4个位置参数 $(t_x, t_y, t_w, t_h)$ 和 $C$ 个分类数。预测框的结果首先根据其前景得分过滤,算法中使用GIoU<sup>[17]</sup>评估预测框与真实框之间距离,保证了检测结果更为准确,其中前景得分Confidence的计算公式为:

$$\text{Confidence} = p_r(\text{Object}) \times \text{GIoU}_{\text{pred}}^{\text{truth}} \quad (1)$$

$$p_r(\text{Object}) \in \{0, 1\}$$

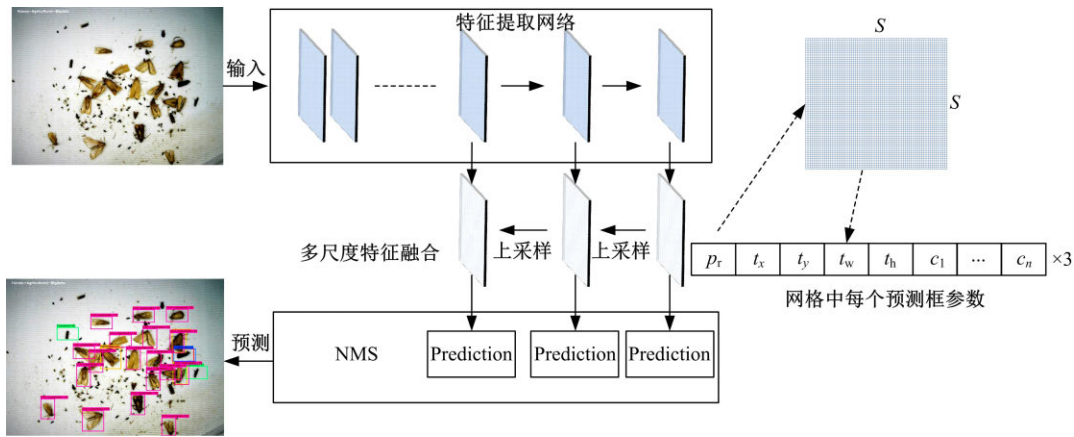


图1 轻量化昆虫检测与分类算法架构

Fig. 1 Framework of lightweight insect detection and classification model

## 1.2 轻量化特征提取网络

为了减少模型性能开销,本文基于DSC重新设计了特征提取网络。DSC基于以下假设:卷积神经网络特征图中跨通道相关性与空间相关性的映射可以分离<sup>[18]</sup>。DSC的原理如图2所示。DSC网络中分为两个周期:第一个周期是执行深

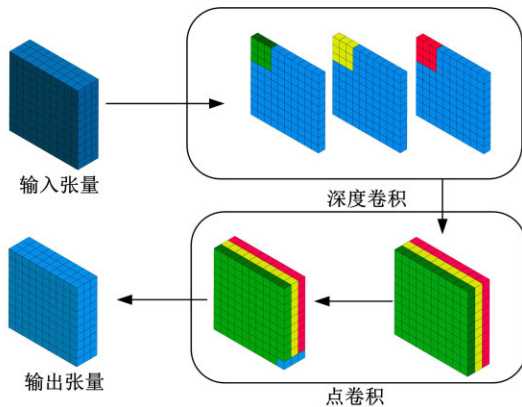


图2 深度可分离卷积原理

Fig. 2 Principle of depthwise separable convolution

度卷积,每个滤波器通道一次仅适用于单个输入通道;第二个周期是通过使用 $1 \times 1$ 滤波器覆盖深度尺寸来执行逐点卷积。DSC可以减少参数量的计算,假设网络输入 $D_F \times D_F \times M$ 的特征层,其中 $M$ 为通道数量,卷积核尺寸为 $D_K \times D_K \times N$ 。当输出特征大小为 $D_P \times D_P \times M$ ,在常规卷积网络中计算量为 $(D_P \times D_P \times M) \times D_K \times D_K \times N$ 。第一步做深度卷积,通过使用尺寸为 $D_K \times D_K \times 1$ 的卷积核对每层输入特征进行卷积,此阶段网络计算量为 $(D_P \times D_P \times 1) \times M \times D_K \times D_K$ ,特征图深度不变。第二步为点卷积操作,卷积核尺寸为 $1 \times 1 \times M$ ,输出特征图尺寸为 $D_P \times D_P \times N$ ,计算量为 $D_K \times D_K \times N \times (1 \times 1 \times M)$ 。DSC计算量等于 $(D_P \times D_P \times 1) \times M \times D_K \times D_K + D_K \times D_K \times N \times (1 \times 1 \times M)$ ,与标准的卷积网络相比,DSC计算大幅减少,其计算量比例为:

$$\frac{(D_P \times D_P \times 1) \times M \times D_K \times D_K + D_K \times D_K \times N \times (1 \times 1 \times M)}{(D_P \times D_P \times N) \times D_K \times D_K \times M} = \frac{1}{N} + \frac{1}{D_K^2} \quad (2)$$

当 $D_K = 3$ 时,DSC比标准卷积少8~9倍的计算量。一方面加快了检测速度,另一方面降低

了内存占用。

标准YOLOv3中网络分辨率为 $416 \times 416$ ,



输入前需要缩放并填充空白以适应分辨率,部分区域无法得到有效利用。由于本文中输入图像尺寸固定,因此特征提取网络输入分辨率被设计为  $640 \times 480$ ,避免了产生大量空白区域,同时能输入更高分辨率的图片。

表 1 为重新设计后的特征提取网络参数,所有的卷积层后都接标准化层和 ReLU 激活层,增强了模型的泛化能力。网络中没有使用池化层,相对地使用步长为 2 的卷积层进行下采样。

表 1 特征提取网络参数

Table 1 Network parameters of feature extraction

类型/步长	卷积核尺寸	输出尺寸
Conv/s2	3*3*3*32	304*240*32
Conv_dw/s1	3*3*32	304*240*32
Conv_dw/s1	1*1*32*64	304*240*64
Conv_dw/s2	3*3*64	152*120*64
Conv_dw/s1	1*1*64*128	152*120*128
Conv_dw/s1	3*3*128	152*120*128
Conv_dw/s1	1*1*128*128	152*120*128
Conv_dw/s2	3*3*128	76*60*128
Conv_dw/s1	1*1*128*256	76*60*256
Conv_dw/s1	3*3*256	76*60*256
Conv_dw/s1	1*1*256*256	76*60*256
Conv_dw/s2	3*3*256	38*30*256
Conv_dw/s1	1*1*256*512	38*30*512
5×	Conv_dw/s1	3*3*512
	Conv_dw/s1	1*1*512*512
	Conv_dw/s2	3*3*512
	Conv_dw/s1	1*1*512*1024
	Conv_dw/s1	3*3*1024
Conv_dw/s1	1*1*1024*1024	19*15*1024

### 1.3 联合交并比

交并比(Intersection over Union, IoU)是目标检测中最常用的标准之一,用于衡量区域之间的重合程度。其存在两个问题:首先,当区域没有重合时, IoU 为 0,无法反映区域之间关系;其次,即使多组区域之间的 IoU 值相同,检测结果也可能存在很大的差异。本文算法使用了基于 IoU 改进的联合交并比(GIoU)用于评估预测框与真实框之间的距离,GIoU 不仅能反映不重叠区域的关系,还能对区域重叠方式进行评估。对于任意两个封闭的区域有:


$$\text{IoU} = |A \cap B| / |A \cup B| \quad (3)$$

$$\text{GIoU} = \text{IoU} - |C \setminus (A \cup B)| / |C| \quad (4)$$


式中:  $A, B \subseteq S \subseteq \mathbb{R}^n$ ;  $C$  为最小的相交凸图形,且

$C \subseteq S \subseteq \mathbb{R}^n$ 。

为了进一步展示 GIoU 的优势,分别使用 IoU 和 GIoU 对两个不同的预测结果进行评估。如图 3 所示,图 3(a)中预测结果部分区域在真实框之外,总体往右上偏移,图 3(b)预测框在真实框内,尽管重合区域相对图 3(a)中更小,但分布更接近于真实目标。当以 IoU 作为标准,两个预测结果得分均为 0.56,无法体现其差异;当以 GIoU 作为标准,图 3(a)得分为 0.51,图 3(b)得分为 0.56,此时模型更趋向于选择图 3(b)中的预测结果。



(a)预测结果1



(b)预测结果2

图 3 IoU 和 GIoU 的预测结果对比

Fig. 3 Comparison of prediction results of IoU and GIoU

## 2 实验结果及分析

### 2.1 实验环境

实验采用 Tensorflow 作为深度学习框架,使用图像处理器加速训练过程。硬件配置为: i7 处理器、32 GB 内存、Nvidia GTX1080ti 显卡;运行环境为: Ubuntu 19.10 系统, Python3.7, Tensorflow1.15, CUDA 库版本为 10.1, cuDNN 库版本为 7.6.5。

## 2.2 数据获取及标注

尽管目前存在一些公开的数据集可用于农业昆虫鉴定,但这些数据难以满足多分类昆虫鉴定任务,特别是自然环境中由于昆虫的多样性,大量非目标昆虫对目标昆虫造成的干扰。本研究中昆虫数据通过植保诱虫灯获取,地点位于湖南省邵阳县境内,诱虫灯于每天19:00~5:00之间开启,通过利用昆虫固有趋光性特点诱捕昆虫。诱捕到

的昆虫通过远红外加热设备杀死,避免活动影响成像效果。杀死的昆虫被放置于平台上,光线和背景均保持不变,由位于正上方的高清摄像头拍照。每张照片中包含多只不同种类昆虫,位置随机分布,不同体型的昆虫可能发生堆叠的情况,保证了算法的鲁棒性。本文对昆虫照片进行了简单预处理,预处理后分辨率为 $3280 \times 2464$ ,图4为部分昆虫训练集样本。




图4 部分昆虫训练集样本

Fig. 4 Some insect training set samples

在农业专家的帮助下,对获取到的数据中大部分昆虫进行了标记和分类,标记工作使用微软公司开发的软件 Visual Object Tagging Tool 完成,储存格式为 Pascal VOC。

由于自然界中生物多样性的特点,同时受限

于采样时间,部分昆虫种类样本数量较少。为了方便实验进行,本次实验选取了部分昆虫,同时将数量较少或危害程度较低的昆虫按照其生物学特性划分到同一个分类当中,最终共分为8类,图5为各分类样本。



图5 各分类样本样本

Fig. 5 Sample of each classification

## 2.3 评估标准

平均精度均值 (Average precision, AP) 是一种用于测量目标检测器精度的流行指标,用于计

算召回率 (Recall) 为 0~1 时的准确率 (Precision) 均值。本文 AP 的计算方法为: 针对每一个不同的召回率 (包括 0 和 1), 选取其大于等于这些召回



率时的准确率最大值,然后计算 Precision-Recall (P-R) 曲线下面积作为 AP 值。具体如下所示:

$$p_{\text{interp}}(r) = \max_{\tilde{r} \geq r} p(\tilde{r}) \quad (5)$$

$$\text{AP} = \sum (r_{n+1} - r_n) p_{\text{interp}}(r_{n+1}) \quad (6)$$

式中:  $r$  为召回率;  $p(\tilde{r})$  为召回率等于  $\tilde{r}$  时的准确率;  $p_{\text{interp}}$  为插值准确率。

在多分类任务中,一般使用多个分类的 AP 平均值,即平均精度均值 (Mean average precision, mAP) 来衡量模型性能。mAP 已成为评估目标检测算法性能的公认方法,被广泛应用于各类目标检测比赛当中。

## 2.4 结果及分析

尽管在训练过程中网络会自动学习并调整预测框大小,但根据目标特征提前设计预测框尺寸,可以提升网络回归效率,本文使用 K-means 聚类算法在训练集真实框中寻找合适的先验框尺寸。由于标准 K-means 中采用欧式距离,会导致大尺寸预测框相比小尺寸预测框产生更多偏差,因此本文使用的距离计算方法为:

$$d(\text{box}_j, \text{centroid}_i) = 1 - \text{GIoU}(\text{box}_j, \text{centroid}_i) \quad (7)$$

式中:  $\text{box}_j$  为第  $j$  个目标框尺寸;  $\text{centroid}_i$  为第  $i$  个聚类中心框尺寸。

训练集中目标框经过 K-means 聚类之后得到的 9 个候选框,其尺寸(宽和高)分别为  $42 \times 65$ ,  $48 \times 39$ ,  $56 \times 62$ ,  $56 \times 79$ ,  $66 \times 50$ ,  $73 \times 40$ ,  $75 \times 71$ ,  $84 \times 53$ ,  $117 \times 108$ 。模型训练循环次数设置为 500,每个循环训练包含 200 步,每步训练样本数为 20,学习速率为 0.001。

图 6 为模型训练过程中训练损失函数下降曲线,模型迭代到第  $2 \times 10^6$  次停止,图中训练损失函数曲线平缓稳定,说明模型已得到充分训练。

表 2 给出了模型对预测各类别的 AP 值,




图 6 训练损失函数曲线

Fig. 6 Training loss function curve

mAP 达到 70.98%,证明本文模型对昆虫多类样本具有足够的检测和识别能力。其中,AP 最高的分类 *Hydrophilidae latreille* 达到 84.38%,而 *Naranga aenescens* 取得了较低的 AP 值 53.82%。导致这种结果的原因:一方面是各分类目标数量不均衡,结合表 1 可知,*Hydrophilidae latreille* 数量远超出其他分类,而 *Naranga aenescens* 相对较少;另一方面是由于鳞翅目昆虫之间具有相似性,因此区分难度更大。

表 2 本文目标检测模型对各测试集中  
各分类昆虫的预测效果

Table 2 Prediction effect of the object detection model  
in this paper on insects in each test set

昆虫类别	AP/%
<i>Chilo suppressalis</i>	70.69
<i>Lepidoptera</i>	64.96
<i>Hydrophilidae latreille</i>	87.38
<i>Coleoptera</i>	71.02
<i>Gryllotalpidae orientalis</i>	87.71
<i>Naranga aenescens</i>	53.82
<i>Kirkaldyia deyrollei</i>	62.04
<i>Cicadellidae</i>	70.21
均值	70.98

考虑到昆虫图像采集过程中昆虫之间的密集堆积可能降低模型预测的准确性,为进一步展示模型鲁棒性,图 7 分别展示了本文模型在不同场景的预测结果。图 7(a)中,背景干扰少,昆虫分布相对均匀,本文模型能准确给出昆虫相对位置和正确分类;图 7(b)中背景较为复杂,存在大量与待检测目标颜色接近的未标记小型昆虫和污渍,但本文模型仍找出大部分目标昆虫的位置和对应分类,说明该模型可以抵抗一定程度的背景干扰;图 7(c)中大量昆虫同时出现,这种情况一般发生在虫情爆发期,挑战模型对密集目标的检测能力,尽管有少量目标昆虫被漏检,但本文模型依然能够找到大部分目标昆虫并给出其正确分类;图 7(d)右下角几只昆虫相互重叠,本文模型仍能准确判断昆虫位置并将对应目标分离。以上结果体现出基于深度学习的多尺度融合目标模型具有良好的鲁棒性和一定的抗干扰能力,足以应对实际使用过程中出现的大部分场景。

## 2.5 可视化特征提取图

在算法输出特征图中,不同深度的卷积层对应不同分类,因此提取特定卷积层输出特征可以展示算法对单个分类的特征提取能力。图 8 为算




图 7 不同场景下的模型检测结果

Fig. 7 Model detection results in different scenarios

法从图像中提取特征图的过程。左侧为输入图像,图中用圆圈标记出 4 只同一种类的昆虫,昆虫周围有较多其他分类昆虫的干扰。右侧为网络提取到的特征图,从上至下加深。随着网络逐渐加深,在原图中圆圈所标记位置亮度增加,与背景逐渐分离,最下方的特征图当中,除了圆圈标记位置有斑点,图像周围区域均无像素。证明了本文算法能有效提取出昆虫特征,同时具备一定的鲁棒性,能够应对较为复杂的背景干扰。




图 8 模型特征提取层可视化

Fig. 8 Model feature extraction layer visualization

2.6 几种模型训练结果

为进一步评估模型的性能,将改进后的模型与 YOLOv3-TINY、YOLOv3 和 Faster R-CNN 几个流行的目标网络进行对比。其中,YOLOv3-TINY 是 YOLOv3 的简化版,仅有两个不同尺度的输出层,通过牺牲精度换取更高的检测速度和更低的资源占用,具有良好的实时性。Faster R-CNN 是经典的 two-stage 目标检测算法之一,实验中使用 VGG16<sup>[19]</sup>作为 Faster R-CNN 特征提取层。各模型使用了同样的训练集进行训练,并对相同的测试集进行检测评估,结果如表 3 所示。

作为 two-stage 目标检测算法,Faster R-

表 3 不同种模型对昆虫的平均识别精度、检测速度和模型尺寸

Table 3 Average recognition accuracy, detection speed and model size of different models for insects

模型	mAP/%	检查速度/ms	参数数量/百万	模型体积/MB
YOLOv3	69.27	53	61	236
YOLOv3-TINY	52.51	32	9	33
Faster R-CNN	68.19	325	136	532
本文	70.98	52	8	30

CNN 模型参数数量多达一亿三千六百万,生成模型占用空间为 532 MB,远高于其他模型,平均每张图像检测耗时为 325 ms,速度较慢。YOLOv3 参数为六千一百万,模型体积约 236 MB,约为 Faster R-CNN 一半,但检测速度远快于 Faster R-CNN,每张照片检测耗时约 53 ms,具有良好的实时性。在所有模型中,YOLOv3-TINY 检测速度最快,每张照片耗时仅 32 ms,生成模型参数仅九百万,生成模型大小为 32 MB,然而良好的性能带来了较大的精度损失,其 mAP 仅 52.51%,为所有模型中最低。本文提出的模型参数仅八百万,生成模型体积仅 30 MB,略低于 YOLOv3-TINY,但远低于 Faster R-CNN 和 YOLOv3,约为 YOLOv3 的八分之一。由于特征提取层当中使用了更大的输入尺寸,速度上较 YOLOv3 并无优势,但检测精度相比 YOLOv3 高出 1.71%,在所有模型中取得了最好的结果。

图 9 为本文模型与 YOLOv3 模型预测结果对比。从图 9 中可以看出:在待检测目标周围无干扰时,两种模型均能给出相对准确的预测结果,然而在待检测目标密集分布、背景中存在干扰或目标发生堆叠时,YOLOv3 模型精度显著下降,本文模型明显优于 YOLOv3 模型。造成这种差距的原因主要有两个:首先,本文模型中特征提取网络使用了更高的输入分辨,其比例接近原图长宽比,减小了图片重采样导致的细节损失,同时也提升了预测特征图中的网格密度。其次,由于模型中使用 GIoU 评估预测框,靠近目标中心且不超出真实区域的预测框能获得更高分值,在目标密集聚集时,可以有效减小因预测框之间因重叠而被过滤。

从以上结果可以得出,本文提出的模型在速度和准确度之间达到了良好的平衡,使用少量参数获得了更高预测精度。






图9 本文算法与YOLOv3算法预测结果对比

Fig. 9 Comparison of prediction results between YOLOV3 and the proposed algorithm

### 3 结束语

为了提高田间昆虫自动识别和分类的精度,提出了基于轻量化深度学习模型的田间昆虫自动识别和分类算法,该模型基于YOLOv3目标检测框架,集成了DSC和GIoU,具有低资源占用和较高的准确性。本文使用3000张诱虫灯下获取的昆虫照片对模型进行训练,结果表明,本文模型对多种昆虫具有良好的识别能力,同时具有良好的鲁棒性,能够应对一定程度的昆虫堆积、背景干扰等问题。与其他算法相比,本文模型在田间昆虫的自动识别和分类准确度与计算机资源消耗之间达到了平衡,同时取得了更高的田间昆虫自动识别和分类正确率。

#### 参考文献:

- [1] 刘海启. 以精准农业驱动农业现代化加速现代农业数字化转型[J]. 中国农业资源与区划, 2019, 40(1): 1-6, 73.  
Liu Hai-qi. Driving agricultural modernization with precision agriculture and accelerating digital transformation of modern agriculture[J]. Chinese Journal of Agricultural Resources and Regional Planning, 2019, 40(1): 1-6, 73.
- [2] 聂娟, 孙瑞志, 邓雪峰, 等. 基于数据世系管理的精准农业不确定性复杂事件处理[J]. 农业机械学报, 2016, 47(5): 245-253.  
Nie Juan, Sun Rui-zhi, Deng Xue-feng, et al. Uncertainty complex event processing of precision agriculture based on data lineage management[J]. Transactions of the Chinese Society for Agricultural Machinery, 2016, 47(5): 245-253.
- [3] 封洪强, 姚青. 农业害虫自动识别与监测技术[J]. 植物保护, 2018, 44(5): 127-133, 198.  
Feng Hong-qiang, Yao Qing. Automatic identification and monitoring technology of agricultural pests [J]. Plant Protection, 2018, 44(5): 127-133, 198.
- [4] 张永玲, 姜梦洲, 俞佩仕, 等. 基于多特征融合和稀疏表示的农业害虫图像识别方法[J]. 中国农业科学, 2018, 51(11): 2084-2093.  
Zhang Yong-ling, Jiang Meng-zhou, Yu Pei-shi, et al. Image recognition of agricultural pests based on multi feature fusion and sparse representation [J]. China Agricultural Science, 2018, 51(11): 2084-2093.



- [5] 马子骥,卢浩,董艳茹. 双通道单图像超分辨率卷积神经网络[J]. 吉林大学学报:工学版, 2019, 49(6): 2089-2097.  
Ma Zi-ji, Lu Hao, Dong Yan-ru. Dual channel single image super-resolution convolution neural network [J]. Journal of Jilin University(Engineering and Technology Edition), 2019, 49(6): 2089-2097.
- [6] 周爱明,马鹏鹏,席天宇,等. 基于深度学习的蝴蝶科级标本图像自动识别[J]. 昆虫学报, 2017, 60(11): 1339-1348.  
Zhou Ai-ming, Ma Peng-peng, Xi Tian-yu, et al. Automatic image recognition of butterflies based on deep learning[J]. Acta Entomology, 2017, 60(11): 1339-1348.
- [7] Cheng Xi, Zhang You-hua, Chen Ju-qiong, et al. Pest identification via deep residual learning in complex background[J]. Computers and Electronics in Agriculture, 2017, 141:351-356.
- [8] 张银松,赵银娣,袁慕策. 基于改进Faster-RCNN算法的粘虫板图像昆虫识别与计数[J]. 中国农业大学学报, 2019, 24(5):115-122.  
Zhang Yin-song, Zhao Yin-di, Yuan Mu-ce. Insect recognition and counting based on improved FAST-RCNN model in the image of armyworm board[J]. Journal of China Agricultural University, 2019, 24(5): 115-122.
- [9] 郭继昌,吴洁,郭春乐,等. 基于残差连接卷积神经网络的图像超分辨率重构[J]. 吉林大学学报:工学版, 2019, 49(5):1726-1734.  
Guo Ji-chang, Wu Jie, Guo Chun-le, et al. Image super-resolution reconstruction based on residual connected convolutional neural network[J]. Journal of Jilin University(Engineering and Technology Edition), 2019, 49(5):1726-1734.
- [10] Huang J, Rathod V, Sun C, et al. Speed/accuracy trade-offs for modern convolutional object detectors [C]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, 2017, 3296-3297.
- [11] 王毅,刘波,熊龙辉,等. 基于深度学习的果园道路导航线生成算法研究[J]. 湖南农业大学学报:自然科学版, 2019, 45(6):674-678.  
Wang Yi, Liu Bo, Xiong Long-ye, et al. Research on algorithm of orchard road navigation line generation based on deep learning[J]. Journal of Hunan Agricultural University(Natural Sciences), 2019, 45(6): 674-678.
- [12] 吴天舒,张志佳,刘云鹏,等. 基于改进SSD的轻量化小目标检测算法[J]. 红外与激光工程, 2018, 47(7): 47-53.  
Wu Tian-shu, Zhang Zhi-jia, Liu Yun-peng, et al. Lightweight small target detection algorithm based on improved SSD [J]. Infrared and Laser Engineering, 2018, 47(7): 47-53.
- [13] 于长东,毕晓君,韩阳,等. 基于轻量化深度学习模型的粒子图像测速研究[J]. 光学学报, 2020, 40(1): 1-15.  
Yu Chang-dong, Bi Xiao-jun, Han Yang, et al. Particle image velocimetry based on lightweight deep learning model[J]. Acta optica Sinica, 2020, 40(1): 1-15.
- [14] 吴天舒,张志佳,刘云鹏,等. 结合YOLO检测和语义分割的驾驶员安全带检测[J]. 计算机辅助设计与图形学学报, 2019, 31(1):126-131.  
Wu Tian-shu, Zhang Zhi-jia, Liu Yun-peng, et al. Driver safety belt detection combined with YOLO detection and semantic segmentation[J]. Journal of Computer-Aided Design & Computer Graphics, 2019, 31(1):126-131.
- [15] 杨观赐,杨静,苏志东,等. 改进的YOLO特征提取算法及其在服务机器人隐私情境检测中的应用[J]. 自动化学报, 2018, 44(12):2238-2249.  
Yang Guan-ci, Yang Jing, Su Zhi-dong, et al. Improved Yolo feature extraction algorithm and its application in privacy situation detection of service robots [J]. Acta Automatica Sinica, 2018, 44(12): 2238-2249.
- [16] 彭明霞,夏俊芳,彭辉. 融合FPN的Faster R-CNN复杂背景下棉田杂草高效识别方法[J]. 农业工程学报, 2019, 35(20):202-209.  
Peng Ming-xia, Xia Jun-fang, Peng Hui. Fast R-CNN based on FPN for efficient weed identification in cotton field[J]. Journal of Agricultural Engineering, 2019, 35(20): 202-209.
- [17] Fu Yi-hao, Aldrich C. Froth image analysis by use of transfer learning and convolutional neural networks [J]. Minerals Engineering, 2018, 115:68-78.
- [18] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.
- [19] Peng Chao, Xiao Te-te, Li Ze-ming, et al. MegDet: a large mini-batch object detector[C]//IEEE Conference on Computer Vision and Pattern Recognition, UTAH, USA, 2018:6181-6189.